

# Identificación de Clumps Astronómicos: Un Enfoque Desde el Cálculo Variacional

Martín Villanueva

4 de abril de 2016

## 1. Introducción

Un cubo espectroscópico de datos puede ser modelado por una función  $f(x, y, z)$ , donde las variables  $(x, y)$  codifican las coordenadas espaciales (*right ascension* y *declination*) respectivamente, y la coordenada  $z$  corresponde a la velocidad radial. Esta función  $f$  asocia una de estas coordenadas, un valor correspondiente a la intensidad de la emisión captada en tal punto. Sin embargo la función  $f$  se conoce en un conjunto discreto de puntos (valores en el cubo de datos).

El problema entonces reside en encontrar una función  $g(x, y, z)$  continua, que aproxime la función  $f$ , de tal manera que estudiando la forma y propiedades de  $g$ , sea posible identificar clumps o regiones de interés en dichas observaciones astronómicas.

## 2. El modelo Variacional

Sea entonces  $f(x, y, z)$  la función de data, y  $g(x, y, z)$  la función que pretende aproximar a  $f$ , se propone entonces el siguiente funcional:

$$\begin{aligned}\Phi(g) &= \int_{\Omega \subset \mathbb{R}^3} L(x, y, z, g, g_x, g_y, g_z) d\Omega \\ &= \int_{\Omega \subset \mathbb{R}^3} (f - g)^2 + \underbrace{\alpha e^{-(f-g)}}_{\text{Penalty term}} + \underbrace{\beta \Psi(g_x, g_y, g_z)}_{\text{Smooth term}} d\Omega\end{aligned}\tag{1}$$

a ser minimizado. La inclusión del *Penalty term* y *Smooth term* en el funcional tiene los siguientes motivos:

1. *Penalty term*: Una de los requisitos sobre la función  $g$  es que esta nunca *sobrepase* a  $f$ . Luego agregando este término se genera una alta penalización sobre el funcional cuando  $g(x, y, z) > f(x, y, z)$ . Esto a su vez puede ser controlado por el parámetro  $\alpha$ .
2. *Smooth term*: Siendo  $\Psi$  una función continua, monótona y creciente, el objetivo de este término es agregar *smoothness* a la solución  $g$ , permitiendo de esta manera filtrar el ruido o distorsiones presentes en la data. El parámetro  $\beta$  permite controlar el peso de este término, y por lo tanto debe estar directamente relacionado con el SNR (*Signal to Noise Ratio*).

Ocupando entonces los resultados del cálculo variacional, sabemos que el funcional  $\Phi(g)$  es minimizado cuando se satisface la siguiente ecuación de Euler-Lagrange:

$$\frac{\partial L}{\partial g} - \frac{d}{dx} \frac{\partial L}{\partial g_x} - \frac{d}{dy} \frac{\partial L}{\partial g_y} - \frac{d}{dz} \frac{\partial L}{\partial g_z} = 0 \quad \forall (x, y, z) \in \Omega\tag{2}$$

### 3. Resolución del Problema

Como primer acercamiento a la solución de (2), se propone el método de colocación. Sea  $\mathcal{N}(\mathbf{x}, \mathbf{x}_0, \sigma)$  una función Gaussiana unitaria, centrada en  $x_0$  con desviación estándar  $\sigma$ , entonces la función  $g$  propuesta es como sigue:

$$g(\mathbf{x}) = \sum_{k=1}^N \gamma_k \mathcal{N}(\mathbf{x}, \mathbf{x}_k, \sigma_k) \quad (3)$$

que corresponde a una combinación lineal de tales Gaussianas. Cada uno de los componentes de la combinación lineal tiene dos parámetros a determinar  $(\gamma_k, \sigma_k)$ .

**Observación:** Eventualmente pueden ser usadas Gaussianas elípticas, asumiendo que el número de parámetros a determinar será mayor: Rotaciones de los ejes, y desviaciones estándar a lo largo de cada semieje.

El problema se resume entonces en encontrar la configuración de  $(\gamma_k, \sigma_k)$ , de modo que  $\Phi(g)$  sea minimizado. Reemplazando (3) en (2) entrega (en general) una ecuación no lineal en  $\{(\gamma_k, \sigma_k)\}_{k=1}^N$ . Como estas son  $2N$  incógnitas, será necesario evaluar (2) en la misma cantidad de puntos en su dominio  $\Omega$ , generando un sistema no-lineal de  $N \times N$ .

### 4. Desafíos

Se listan a continuación un serie de problemáticas en cuanto al modelo y su implementación

1. Penalizar correctamente los casos donde  $g > f$ .
2. Establecer una relación directa entre el parámetro  $\beta$  y el  $SNR$  de la data.
3. Establecer la cantidad  $N$  de Gaussianas a ocupar en la construcción de  $g$ .
4. Seleccionar los puntos de colocación  $x_k$  (Uniforme, Random, Quasi-Random, Ocupando alguna heurística, etc).
5. Seleccionar los puntos objetivos donde evaluar (2).
6. Usualmente para que el método de colocación sea exitoso, requiere valores de  $N$  muy grandes. Esto implica evaluaciones costosas para  $g$ ,  $g_x$ ,  $g_y$ ,  $g_z$  las cuales son expresiones que deben computarse en cada evaluación de (3) en algún punto del dominio. Una posible solución a este problema es ocupar FGT (Fast Gauss Transform), pero hay que considerar que las funciones  $g_x$ ,  $g_y$ ,  $g_z$  no son precisamente sumas de Gaussianas, por lo cual modificaciones deben hacerse sobre FGT tradicional.
7. Debe hallarse una manera eficiente de resolver el sistema no lineal de  $N \times N$  resultante. Posibles opciones son ocupar el método de Newton (con Jacobiano explícito), o las soluciones estables de un sistema dinámico.